
Transformers

Transformers


- Transformers wurden 2017 von Google Brain eingeführt
- "Attention is all you need!"
- Ursprünglich für Machine Translation
- Schnell für alle NLP-Tasks
- Dann auch für viele andere Bereiche ...

Encoder-Decoder Architektur




- Der ursprüngliche Transformer ist eine Encoder-Decoder Architektur
- Für Machine Translation ist diese Setup sehr intuitiv: Der Encoder encoded den Ausgangssatz ... der Decoder nimmt diese Codierung und baut daraus die Übersetzung


Encoder



Encoder




Self-Attention




• Vaswani, Ashish, et al. "Attention is all you need." *Advances in neural information processing systems*. 2017. (10000 citations!)

An attention function can be described as mapping a query and a set of key-value pairs to an output, where the **query Q**, **keys K**, **values V**, and output are all vectors. The output is computed as a weighted sum of the values, where the weight assigned to each value is computed by a compatibility function of the query with the corresponding key.




Wie wird der Vektor verwurstet?


- 1. Er wird in einen Vektor **Q** verwandelt.
- 2. Dann mit den Keys des Kontextes verglichen.
- 3. Und dann aus den Values des Kontextes gewichtet neu berechnet.



Normalisierung



Decoder



Decoder

Decoding time step: 1 2 3 4 5 6 OUTPUT

